
第 3 章

Scipy 及其基本使用

本章配套：正文小节 / 上机 lab / 练习 quiz / 常见误区与技巧

3. SciPy 及其基本使用（新版讲义）

本页是第 3 章的[章首页（索引）](#)。正文位于 01-微积分工具包.md ~ 07-常见误区与技巧.md，与原版资料完全分离（原版见 ../../原始资料/chap3/）。

本章概览

SciPy 是建立在 NumPy 之上的科学计算核心库，把数值积分、常微分方程、优化、插值、统计检验、傅里叶变换与信号处理等“半成品”算法封装成稳定、经过验证的函数。它是《数学建模导论》与后续 Pandas、Matplotlib、Statsmodels、scikit-learn 各章的地基：只要问题的数学模型可写成函数/矩阵，通常就能用 SciPy 快速求数值解。

本章按功能分成五个工具包：

- **微积分工具包** (scipy.integrate)：数值积分、微分方程数值解；
- **优化工具包** (scipy.optimize)：求根、无约束/约束极值、线性规划、指派、曲线拟合；
- **插值工具包** (scipy.interpolate)：一维/多维插值、样条；
- **假设检验工具包** (scipy.stats)：正态性检验、t 检验、卡方检验、方差分析；
- **傅里叶变换工具包** (scipy.fft / scipy.signal)：FFT、频谱分析、滤波器。

学习目标

学完本章，你应该能够：

1. 用 quad/dblquad/trapezoid 计算定积分，用 odeint/solve_ivp 求解一阶、二阶及高阶常微分方程（组）。
2. 用 fsolve/root/brentq 求方程（组）的根，用 brent/fmin/minimize 求极值，用 linprog/linear_sum_assignment 解线性规划与指派问题。
3. 用 curve_fit/leastsq 做非线性最小二乘拟合，读取 pcov 估计参数误差。
4. 用 CubicSpline/RegularGridInterpolator/griddata 做一维与多维插值，理解插值 vs 拟合的区别。
5. 用 shapiro/ttest_ind/ttest_rel/chi2_contingency/f_oneway 完成常用假设检验并正确解读 p 值。
6. 用 rffft/rfftfreq 做频谱分析，用 butter+lfilter 设计低通/高通/带通/带阻滤波器。
7. 完成一个综合小案例（如“传感器信号分析”），体会 SciPy 在真实数据上“积分 + 拟合 + 插值 + 检验 + FFT”的组合用法。

案例索引

案例卡	所在节	技术点	难度
1. 用 quad 求定积分并和数值微分结果对照	01 微积分工具包	quad、trapezoid、自适应积分	★☆☆
2. 用 curve_fit 拟合实验数据并解释参数含义	02 优化工具包	curve_fit、pcov、参数标准误、RMSE	★★☆
3. 一维插值 vs 多项式拟合：缺失值用 CubicSpline 补全	03 插值工具包	CubicSpline、polyfit、RMSE	★★☆
4. 综合案例：传感器信号分析	06 综合案例	插值 + FFT + 拟合 + 积分 + 检验	★★★

先修要求与运行环境

- 熟悉 Python 基础语法；建议先学第 1 章 NumPy（数组、广播、矩阵运算）与第 2 章 SymPy（符号求导/积分）。
- 安装 Python 3.10+ 与 SciPy:

```
pip install numpy scipy matplotlib pandas
# 若要做事后多重比较 (Tukey HSD) 或回归诊断, 再安装
pip install statsmodels
```

- 本讲义所用版本: SciPy 1.15.2、NumPy 2.1.2、Matplotlib 3.10.1、statsmodels 0.14.6（验证环境）。
- 推荐在 JupyterLab / VS Code 中打开 .ipynb 练习；命令行列出的脚本直接保存为 .py 运行即可。

本章目录

小节	文件	内容
01 微积分工具包	01-微积分工具包.md	数值积分、二重积分、梯形法、odeint/solve_ivp 解 ODE
02 优化工具包	02-优化工具包.md	求根、极值、线性规划、指派、最小二乘拟合
03 插值工具包	03-插值工具包.md	一维样条、多维插值、散点插值、插值 vs 拟合
04 假设检验工具包	04-假设检验工具包.md	正态性检验、t 检验、卡方、ANOVA、多重比较
05 傅里叶变换工具包	05-傅里叶变换工具包.md	FFT、频谱、滤波器设计
06 综合案例	06-综合案例.md	传感器信号分析（插值 + FFT + 拟合 + 检验 + 积分，含配图）
07 常见误区与技巧	07-常见误区与技巧.md	易错点速查表、性能/调试/自测清单

数学预备与附录

本章的数值方法/统计背景已集中到附录《数学与算法补充》:

- **B 微积分与数值方法**: B.3.1 数值积分与微分、B.3.2 优化、B.3.3 插值、B.3.4 FFT、B.3.5 ODE;
- **C 概率统计基础**: C.3 假设检验与置信区间;
- [打开附录 B](#) | [打开附录 C](#) | [附录索引](#)

每个工具包开讲前，先翻对应“ 算法思路” 小节（3~5 分钟）。

练习与上机入口

- [本章练习 \(exercises/\)](#) : 作业题、自测 quiz、参考答案。
- [本章上机 \(lab/\)](#) : 循序渐进的上机 notebook，含环境自检、逐点演练与综合任务。
- [本章参考与延伸阅读 \(references.md\)](#) : 官方文档、精品教程、习题集、中文资料。
- [教学说明 \(teaching.md\)](#) : 课时安排、重点难点、考核建议（教师用）。

建议课时

环节	学时	对应内容
讲课	3-4 学时	01-05 正文 + 06 案例讲解
上机	2-3 学时	lab/ 逐题完成; 课后完成 exercises/ 作业

使用说明

- **学生**: 先读 01-05 正文并运行代码 → 完成 lab 上机 → 提交 exercises 作业 → 自测 quiz 检验。生词/公式不懂时, 到 references.md 找官方对应章节。
- **教师**: 按 teaching.md 的课时表讲; lab 可作为上机课内容; exercises 中的 quiz 带自动评分, 可直接回收。

01 微积分工具包：数值积分与微分方程数值解

本节对应原版 3.1 的内容，并增补学习目标、常见误区、思考题与延伸阅读。所有代码均在 SciPy 1.15.2 / NumPy 2.1.2 环境实际运行验证。配套图：images/ode_solution.png（由 build/make_chap3_figures.py 生成）。

本节目标

- 会用手工梯形公式近似定积分，理解“分割越细越精确”的收敛思想；
- 会用 `scipy.integrate.quad` 求一维定积分，用 `dblquad/nquad` 求多重积分；
- 会用 `trapezoid` 对离散数据（实验数据/数值解）做数值积分；
- 会用 `odeint/solve_ivp` 求解一阶、高阶及常微分方程组；
- 了解 `solve_bvp` 用于边值问题。

先修

- 第 1 章 NumPy: `np.linspace`、`np.arange`、数组切片；
- 第 2 章 SymPy: 知道解析积分与数值积分的区别（可先跳过）。

官方文档 / 参考入口

- SciPy 积分模块总览: [链接](#)
 - `quad`: [链接](#)
 - `solve_ivp`: [链接](#)
-

1.1 为什么需要数值积分

很多函数的原函数无法写成初等函数（例如 e^{-x^2} 、 $\sin(x^2)$ ），或者我们只有离散的实验采样点。此时只能用数值方法求定积分。

1.1.1 梯形法：从手工到库函数

把 $[a, b]$ 等分成 n 段，每段用梯形近似曲线下面积：

$$\int_a^b f(x) dx \approx \sum_{i=0}^{n-1} \frac{f(x_i) + f(x_{i+1})}{2} \cdot h, \quad h = \frac{b-a}{n}$$

下面用 Python 实现 $\int_0^1 x^2 dx$ ，理论值 $\frac{1}{3}$ 。

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
```

```
def trapezoidal_rule(f, a, b, n):
    h = (b - a) / n
    s = 0.5 * (f(a) + f(b))
    for i in range(1, n):
        s += f(a + i * h)
```

```

    return s * h

def f(x):
    return x**2

for n in (10, 100, 1000):
    print(f"n={n:5d} approx={trapezoidal_rule(f, 0, 1, n):.10f}")
print("theoretical = 1/3 =", 1/3)

n= 10 approx=0.3350000000
n= 100 approx=0.3333500000
n= 1000 approx=0.3333335000
theoretical = 1/3 = 0.3333333333333333

```

可见 n 越大, 结果越接近 $\frac{1}{3}$ 。

1.1.2 用 quad 求一维定积分

`quad(func, a, b, args=...)` 返回二元组 (积分值, 误差估计)。它使用自适应算法, 精度远高于固定步长的梯形法。

```

import numpy as np
from scipy.integrate import quad

v1, e1 = quad(lambda x: x**2, 0, 1)
v2, e2 = quad(lambda x: np.exp(-x**2), -np.inf, np.inf)
print(f"({v1:.6f}, {e1:.2e})")
print(f"({v2:.6f}, {e2:.2e})")

( 0.333333, 3.70e-15 )
( 1.772454, 1.42e-08 )

```

第二个例子是高斯积分 $\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi} \approx 1.77245$, `quad` 也擅长处理无穷积分。## 案例卡 1: 用 `quad` 求定积分并和数值微积分结果对照

目标

用 `scipy.integrate.quad` 求 $\int_0^1 x^2 dx$ (理论值 $1/3$), 再用手工梯形法 (`trapezoid`) 在不同分割数下对照, 直观看到: `quad` 一次就给到高精度, 而固定步长梯形法需要不断加密才能靠近。

代码

```

import numpy as np
from scipy.integrate import quad, trapezoid
np.set_printoptions(precision=4, suppress=True)

def f(x):
    return x**2

val, err = quad(f, 0, 1)
x10 = np.linspace(0, 1, 11)
x100 = np.linspace(0, 1, 101)
x1000 = np.linspace(0, 1, 1001)

```

```
print("quad      =", f"{val:.8f}", "   err =", f"{err:.2e}")
print("trapezoid n=10   =", f"{trapezoid(f(x10), x10):.8f}")
print("trapezoid n=100  =", f"{trapezoid(f(x100), x100):.8f}")
print("trapezoid n=1000 =", f"{trapezoid(f(x1000), x1000):.8f}")
print("理论值 1/3      =", f"{1/3:.8f}")
```

运行结果（已运行核验）

```
quad      = 0.33333333   err = 3.70e-15
trapezoid n=10   = 0.33500000
trapezoid n=100  = 0.33335000
trapezoid n=1000 = 0.33333350
理论值 1/3      = 0.33333333
```

讲解

一句话解释：quad 像“聪明的测量员”，哪里弯曲得厉害就自动多量几次；梯形法像“平均每次分成几段”，分得越细才越准。

- $f(x) = x^2$ 是被积函数，`quad(f, 0, 1)` 的 0、1 是上下限，`val` 是积分值、`err` 是误差估计。
- `np.linspace(0, 1, 11)` 把区间切成 10 段，`trapezoid(f(x10), x10)` 用这些离散点做梯形面积求和，所以“`n=10`”表示 10 段。
- 对比结果：quad 直接到 0.33333333（差约 10^{-15} ），而梯形法在 `n=10` 时是 0.33500000，`n=1000` 才到 0.33333350——这说明自适应积分“省力又准”。
- 理论值 $1/3 = 0.33333333$ （保留 8 位小数），和 quad 一致。

主要用法 / API

需求	写法	返回
一维定积分	<code>quad(func, a, b)</code>	<code>(value, error)</code>
无穷积分	<code>quad(func, -np.inf, np.inf)</code>	<code>(value, error)</code>
离散数据积分	<code>trapezoid(y, x)</code>	标量
等高精度输出	<code>f"{v:.8f}" / round(v, 8)</code>	字符串/浮点

常见错误

- 忘记 quad 返回的是元组，直接 `quad(...)` 当数值用；
- 把 `trapezoid(y, x)` 的参数顺序写成 `trapezoid(x, y)`；
- 用 `np.linspace(0, 1, 10)` 却以为自己有 10 段，实际是 10 个点、9 段；
- 不设 `np.set_printoptions(precision=4, suppress=True)` 导致数组/小数输出不整洁。

拓展 / 跟练

1. 把被积函数换成 $f(x) = \exp(-x^2)$ ，看看 quad 和梯形法各差多少。
2. 用 `quad(f, 0, 1, epsabs=1e-10)` 指定绝对误差，观察 `err` 变化。
3. 把区间改成 0 到 2，理论值变成 $8/3$ ，验证 quad。
4. 用 `scipy.integrate.nquad` 算 $\int_0^1 \int_0^1 xy \, dx \, dy$ ，和 quad 逐次积分结果对比。

1.1.3 二重积分 dblquad

计算 $\int_0^1 \int_0^x xy \, dy \, dx$ 。注意内层积分上下限函数以积分变量为自变量。

```
from scipy.integrate import dblquad
```

```
def f(y, x):
    return x * y
```

```
result, err = dblquad(f, 0, 1, lambda x: 0, lambda x: x)
print(result, err)
```

```
0.125 5.515032205777789e-15
```

理论值 $\frac{1}{8}$ ；若积分变量更多，可用 tplquad (三重) 或 nquad (任意维)。

1.1.4 对离散数据积分 trapezoid

实验数据只有采样点 (x_i, y_i) ，没有函数表达式，用 trapezoid(y, x)。注意：在 SciPy 1.15 中函数名为 trapezoid (老版本叫 trapz)。

```
from scipy.integrate import trapezoid
import numpy as np
```

```
x = np.linspace(0, 1, 100)
y = x**2
print(trapezoid(y, x))
```

```
0.33335033840084355
```

1.2 常微分方程数值解

大多数微分方程没有解析解，scipy.integrate 给出“列表法”近似解：针对自变量数组中的每个取值，给出高频精度的因变量值。

1.2.1 一阶 ODE: odeint

求 $\frac{dy}{dt} = \sin(t^2)$, $y(0) = 1$ 。

```
import numpy as np
from scipy.integrate import odeint
```

```
def dy_dt(y, t):
    return np.sin(t**2)
```

```
y0 = [1]
t = np.arange(0, 10, 0.1)
y = odeint(dy_dt, y0, t)
print(f"len = {len(y)}   y(0) = {y[0,0]}   y(9.9) = {y[-1,0]}")
```

```
len = 100   y(0) = 1.0   y(9.9) = 1.6678897279551907
```

odeint 默认 func(y, t, *args) 参数顺序 (y 在前、t 在后)，基于 LSODA 可自动处理刚性问题。

1.2.2 二阶 ODE 转一阶方程组

求 $y'' + y = 0$, $y(0) = 1$, $y'(0) = 0$ 。令 $y_1 = y$, $y_2 = y'$, 则 $y'_1 = y_2$, $y'_2 = -y_1$ 。

```
def second_order(y, t):
    y1, y2 = y
    return [y2, -y1]
```

```
y = odeint(second_order, [1, 0], t)
print("y(9.9) =", y[-1,0], " y'(9.9) =", y[-1,1])
```

```
y(9.9) = -0.8891913778545403 y'(9.9) = 0.45753579354898755
```

该方程解析解为 $y = \cos t$, $\cos(9.9) \approx -0.8892$, $y'(9.9) = -\sin(9.9) \approx 0.4575$, 数值解一致。

1.2.3 高阶 ODE: 三阶方程

对 $y''' + y'' + y' + y = 0$, 令 $y_1 = y$, $y_2 = y'$, $y_3 = y''$, 化为三个一阶方程: $y'_1 = y_2$, $y'_2 = y_3$, $y'_3 = -y_1 - y_2 - y_3$ 。

```
def third_order(y, t):
    y1, y2, y3 = y
    return [y2, y3, -y1 - y2 - y3]
```

```
y = odeint(third_order, [1, 0, 0], t)
print(f"y(9.9) = {y[-1,0]:.8f} y'(9.9) = {y[-1,1]:.8f} y''(9.9) = {y[-1,2]:.8f}")
```

```
y(9.9) = -0.67333854 y'(9.9) = -0.21585283 y''(9.9) = 0.67338872
```

1.2.4 更新更灵活的 solve_ivp

`solve_ivp` 是较新且更灵活的接口, 支持 `t_eval`、事件检测、更多求解器。注意它的导数函数签名是 `fun(t, y)` (`t` 在前)。

```
from scipy.integrate import solve_ivp
```

```
def deriv(t, y):
    return -2 * y
```

```
sol = solve_ivp(deriv, (0, 5), [1], t_eval=np.linspace(0, 5, 100))
print("y(5) =", sol.y[0, -1])
print("n_points =", len(sol.t))
```

```
y(5) = 4.572378941563548e-05
n_points = 100
```

解析解 $y = e^{-2t}$, $e^{-10} \approx 4.54 \times 10^{-5}$, 数值解一致。

1.2.5 边值问题 solve_bvp

边值问题 (BVP) 给定区间两端条件, 且需要初始猜测。以下求 $y'' = 6x$, 边界 $y(0) = 0$, $y(1) = 1$ (解析解 $y = x^3$)。

```
from scipy.integrate import solve_bvp
```

```
def fun(x, y):
```

```

    return np.vstack((y[1], 6*x))

def bc(ya, yb):
    return np.array([ya[0], yb[0]-1])

x = np.linspace(0, 1, 20)
y = np.zeros((2, x.size))
sol = solve_bvp(fun, bc, x, y)
print(f"sol.x.size = {sol.x.size}    y_mid = {round(sol.y[0,10], 6)}")
print(f"truth x^3 = {round(x[10]**3, 6)}")

sol.x.size = 20    y_mid = 0.145794
truth x^3 = 0.145794

```

常见误区

1. **trapz 在新版 SciPy 已改名**: 用 trapezoid; 老教程的 `from scipy.integrate import trapz` 在 1.15 会报 `ImportError`。
2. **odeint 导数函数参数顺序是 (y, t)**, 而 `solve_ivp` 是 (t, y), 二者顺序相反, 容易写错。
3. **solve_ivp 用 t_span=(t0,tf)**, 不是 **t0,tf 分开传**; 想要稀疏输出用 `t_eval`。
4. **把 quad 返回元组当成单个值**: 要取 `quad(...)[0]` 或解包 (value, err)。
5. **高阶 ODE 忘记降阶**: 必须把 y'' (或更高阶) 化成两个/多个一阶方程组成的方程组。
6. **odeint 时间序列必须单调**: t 数组要递增或递减, 且首项对应初始时间。

思考题

1. 为什么 n 增大时梯形法误差 $O(h^2)$, 而 `quad` 采用自适应细分能更快收敛?
2. 用 `solve_ivp` 重写 1.2.2 的二阶 ODE, 并在 $t=0, 2, 4, 9.9$ 处与 `odeint` 结果对比。
3. 说明 `solve_ivp` 的事件 (events) 可以解决什么问题 (例如 “何时达到给定阈值”)。

动手练习

- 用 `trapezoid` 计算 $\int_0^2 \sin(x) dx$ (理论值 $1 - \cos 2$);
- 用 `quad` 计算 $\int_0^1 e^{-x^2} dx$, 并与 `trapezoid` 的 $n=1000$ 比较精度;
- 求解 SEIR 易感-暴露-感染-康复模型 (参数见原版 3.1) 并画出四条曲线;
- 用 `solve_ivp` 求解 Lorenz 系统并画 3D 轨迹 (参数 $\sigma = 10, \rho = 28, \beta = 8/3$)。

延伸阅读

- SciPy 官方 ODE 教程: [链接](#)
- SciPy 积分教程: [链接](#)
- 数值积分/ODE 的数学课件 (中文): [链接](#)

02 优化工具包：求根、极值、规划与曲线拟合

本节对应原版 3.2 的内容，并增补学习目标、常见误区、思考题与延伸阅读。所有代码均在 SciPy 1.15.2 / NumPy 2.1.2 环境实际运行验证。配套图：images/optimize_fit.png（由 build/make_chap3_figures.py 生成）。

本节目标

- 会用 fsolve/root 求非线性方程（组），用 brentq 等一维求根；
- 会用 brent（一维）、fmin（Nelder-Mead）、minimize（多种算法）求极值；
- 会用 linprog 解线性规划，用 linear_sum_assignment 解指派问题；
- 会用 leastsq/curve_fit 做非线性最小二乘拟合，并读取协方差矩阵 pcov；
- 理解“初值敏感”与“约束处理”对数值优化的影响。

先修

- 第 1 章 NumPy：数组运算、随机数生成、np.linalg；
- 微积分求导/偏导概念；第 2 章 SymPy 可辅助写目标函数。

官方文档 / 参考入口

- SciPy 优化模块总览：[链接](#)
 - root：[链接](#)
 - minimize：[链接](#)
 - curve_fit：[链接](#)
-

2.1 函数的零点与方程的解

2.1.1 fsolve：求单个方程/方程组的根

求 $x^2 - 612 = 0$ 的正根。fsolve 用最小二乘（典型 Levenberg-Marquardt）从初值出发迭代。

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
from scipy.optimize import fsolve
```

```
def func(x):
    return x**2 - 612
```

```
print(fsolve(func, 10.0))
```

```
[24.7386]
```

注意： $\sqrt{612} \approx 24.7386$ ；若从 -10 出发会得到负根。fsolve 的结果依赖初值，且可能只找到最接近初值的一个根。

2.1.2 root：更多算法与方程组

求方程组
$$\begin{cases} x^2 + y^2 - 4 = 0 \\ x - y - 1 = 0 \end{cases} .$$

```

from scipy.optimize import root
import numpy as np

def func(v):
    x, y = v
    return [x**2 + y**2 - 4, x - y - 1]

sol = root(func, [0, 0])
print(sol.x, sol.success, sol.message)

[-0.8229 -1.8229] True The solution converged.

```

root 返回 OptimizeResult: x 为解, success 是否成功, message 终止信息, 也可用 method 选择 hybr/lm/krylov 等。

2.1.3 一维求根 brentq

brentq 需要提供包含根的区间 $[a, b]$, 要求 $f(a)$ 与 $f(b)$ 异号。求 $x^2 - 2 = 0$ 的根 ($\sqrt{2}$)。

```

from scipy.optimize import brentq
print(brentq(lambda x: x**2 - 2, 1, 2))

1.4142135623731364

```

注意: brent (无 q) 求的是**最小值**, brentq (带 q) 求**根**, 二者用途不同, 切勿混淆。

2.2 函数的极值优化

2.2.1 一维无约束: brent

求 $f(x) = (x - 1)^2$ 的最小值点。

```

from scipy.optimize import brent
print(brent(lambda x: (x-1)**2, brack=(0, 2)))

0.9999999999999998

```

brack 是包含极小值的三点/两点区间。可设 full_output=True 获得函数值、迭代次数等。

2.2.2 多维无约束: fmin (Nelder-Mead)

求 $f(x) = ax^2 + bx + c$, 令 $a = 1, b = 3, c = 2$ 。

```

from scipy.optimize import fmin
import numpy as np

def quadratic(x, a, b, c):
    return a * x**2 + b * x + c

res = fmin(quadratic, np.array([1.0]), args=(1, 3, 2), full_output=True, disp=False)
print("x =", res[0], " fmin =", res[1], " iter =", res[2], " nfev =", res[3])

x = [-1.5]  fmin = -0.25000000000000004  iter = 19  nfev = 38

```

理论最小点 $x = -b/(2a) = -1.5$, $f_{\min} = c - b^2/(4a) = 2 - 9/4 = -0.25$ 。

2.2.3 通用接口 minimize

minimize 是更强大、更推荐的多维优化接口，可自动/手动选择算法。

无约束 (Nelder-Mead):

```
from scipy.optimize import minimize

def obj(x):
    return (x[0]-1)**2 + (x[1]-2)**2

res = minimize(obj, [0, 0], method="Nelder-Mead")
print(res.x, res.fun, res.success)

[1. 2.] 1.869184419935774e-09 True
```

带约束 (SLSQP): 最小化 $x_1^2 + x_2^2$, 约束 $x_1 + x_2 \geq 1$, $x_1, x_2 \geq 0$ 。

```
cons = [{"type": "ineq", "fun": lambda x: x[0] + x[1] - 1}]
res = minimize(lambda x: x[0]**2 + x[1]**2, [0, 0], method="SLSQP",
               constraints=cons, bounds=[(0, None), (0, None)])
print(res.x, res.fun, res.success)

[0.5 0.5] 0.5000000000000002 True
```

约束写成 $\text{fun}(x) \geq 0$ 形式; bounds 定义各变量取值范围。

2.2.4 线性规划 linprog

最小化 $c^T x$, 受 $A_{ub}x \leq b_{ub}$ 、 $A_{eq}x = b_{eq}$ 、 $x \geq 0$ 约束。

```
import numpy as np
from scipy.optimize import linprog

c = [-29, -45, 0, 0]
A_ub = [[1, -1, -3, 0], [-2, 3, 7, -3]]
b_ub = [5, -10]
A_eq = [[2, 8, 1, 0], [4, 4, 0, 1]]
b_eq = [60, 60]
bounds = [(0, None)] * 4

res = linprog(c, A_ub=A_ub, b_ub=b_ub, A_eq=A_eq, b_eq=b_eq, bounds=bounds)
print(np.round(res.x, 2), round(res.fun, 2), res.success)

[9.2 5.2 0. 2.4] -500.8 True
```

2.2.5 指派问题 linear_sum_assignment

给定成本矩阵, 求 “一人一任务” 的最小总成本分配 (匈牙利算法)。

```
import numpy as np
from scipy.optimize import linear_sum_assignment

cost = [[4, 1, 3], [2, 0, 5], [3, 2, 2]]
row_ind, col_ind = linear_sum_assignment(cost)
print("rows =", row_ind, " cols =", col_ind)
print("min cost =", np.array(cost)[row_ind, col_ind].sum())

rows = [0 1 2] cols = [1 0 2]
min cost = 5
```

即工人 A → 任务 2、B → 任务 1、C → 任务 3，总成本 1+2+2=5。

2.3 曲线拟合 (最小二乘)

2.3.1 leastsq

手动给误差向量，最小化 $\sum r_i^2$ 。

```
import numpy as np
from scipy.optimize import leastsq

def model(x, a, b, c):
    return a*x**2 + b*x + c

def residuals(p, x, y):
    a, b, c = p
    return y - model(x, a, b, c)

rng = np.random.default_rng(7)
x = np.linspace(-10, 10, 50)
y = model(x, 2, 3, 1) + rng.normal(0, 2, len(x))

params, flag = leastsq(residuals, [0, 0, 0], args=(x, y))
print(np.round(params, 4))

[ 2.0191  3.0387 -0.2494]
```

2.3.2 更友好的 curve_fit

curve_fit(model, xdata, ydata, p0=...) 自动构造残差，返回 (popt, pcov)。

```
import numpy as np
from scipy.optimize import curve_fit

popt, pcov = curve_fit(model, x, y, p0=[0, 0, 0])
perr = np.sqrt(np.diag(pcov))
print("popt =", np.round(popt, 4))
print("stderr =", np.round(perr, 4))

popt = [ 2.0191  3.0387 -0.2494]
stderr = [0.0078 0.0409 0.3616]
```

案例卡 2：用 curve_fit 拟合实验数据并解释参数含义

目标

给一组“随指数衰减”的噪声数据，用 curve_fit 拟合模型 $y = Ae^{-kt} + C$ 得到 A、k、C，并读 pcov 拿到参数标准误，从而解释每个参数的物理含义。

代码

```
import numpy as np
from scipy.optimize import curve_fit
np.set_printoptions(precision=4, suppress=True)

def decay(t, A, k, C):
```

```

    return A*np.exp(-k*t) + C

rng = np.random.default_rng(7)
t = np.linspace(0, 5, 60)
y = decay(t, 5.0, 1.5, 0.5) + rng.normal(0, 0.08, t.size)

popt, pcov = curve_fit(decay, t, y, p0=[1, 1, 0])
perr = np.sqrt(np.diag(pcov))
print("A =", round(popt[0], 4), " k =", round(popt[1], 4), " C =", round(popt[2], 4))
print("stderr =", np.round(perr, 4))
residuals = y - decay(t, *popt)
print("RMSE =", round(float(np.sqrt(np.mean(residuals**2))), 4))
```

运行结果（已运行核​验）

```

A = 5.0274    k = 1.5355    C = 0.4946
stderr = [0.0454 0.0257 0.0131]
RMSE = 0.0693
```

讲解

一句话解释: `curve_fit` 就是“先写出公式形状, 再让计算机微调那几个系数, 使曲线尽量贴近实验点”。

- `decay(t, A, k, C)` 是模型: A 是初始幅度 ($t = 0$ 时几乎等于 $A + C$), k 是衰减速率 (越大衰减越快), C 是最终基线 (衰减结束后接近的值)。
- `rng.normal(0, 0.08, t.size)` 给每个时间点加测量噪声, 所以不能直接“插值”把所有点连起来; 拟合是“容忍噪声”。
- `p0=[1, 1, 0]` 是初值: 非线性最小二乘需要合理的起点, 否则可能不收敛。
- `popt` 是拟合后参数, `pcov` 是参数协方差矩阵, `np.sqrt(np.diag(pcov))` 得到每个参数的标准误 (约等于拟合值的不确定度)。
- `RMSE = 0.0693` 与噪声标准差 `0.08` 同量级, 说明拟合没有“过拟合”噪声。

主要用法 / API

需求	写法	说明
非线性最小二乘拟合	<code>curve_fit(func, x, y, p0=...)</code>	返回 (<code>popt</code> , <code>pcov</code>)
参数标准误	<code>np.sqrt(np.diag(pcov))</code>	协方差矩阵主对角线开方
残差平方根误差	<code>np.sqrt(np.mean((y - func(x, *popt))**2))</code>	RMSE
初值设置	<code>p0=[...]</code>	尽量接近真实值
提高迭代上限	<code>maxfev=50000</code>	复杂模型防“达到最大调用次数”

常见错误

- 不给 `p0` 或 `p0` 离真值太远, 导致不收敛或收敛到错误参数;
- 把 `curve_fit` 的结果当成“一定正确”, 应同时看 `pcov`/标准误;
- 对含噪声数据用样条插值“穿点”, 而不是拟合; 两者语义不同 (见案例 3);
- 忘记 `decay(t, *popt)` 中的 `*`, 传成单个数组导致维度错误。

拓展 / 跟练

- 1. 把模型改成 $y = A \cdot \exp(-k \cdot t)$ (去掉 C), 看 C 消失后拟合结果是否稳定。
- 2. 把噪声标准差改成 0.5, 观察标准误差变大、RMSE 变大。
- 3. 用 `maxfev=50000` 重新拟合, 并打印 `popt` 与 `perr`。
- 4. 换一个“双指数”模型 $A_1 e^{-k_1 t} + A_2 e^{-k_2 t} + C$, 尝试拟合并解释参数。

常见误区

#	误区	正确做法
1	用 brent 求根	求根用 brentq/fsolve/root
2	fsolve 不设初值 / 期望得到全部根	一维用 brentq 且给出异号区间; 多根问题改变初值或多个区间
3	fmin 的 full_output 返回顺序误读	返回 (xopt, fopt, iter, funcalls, ...), iter/funcalls 是整数
4	linprog 目标默认最小化, 忘了 c 取负号	若原问题是最大化, 把 c 取负转成最小化
5	linear_sum_assignment 直接返回成本矩阵	返回 row_ind, col_ind, 需用 <code>cost[row_ind, col_ind].sum()</code> 得成本
6	minimize 约束符号写反	ineq 表示 $\text{fun}(x) \geq 0$; 等号约束用 eq
7	不设 p0 就 curve_fit	初值不良会导致不收敛或收敛到错误参数, 应给接近真实值的 p0

思考题

- 1. 为什么 brentq 比 fsolve 在一维问题上更稳定? 各需要什么前提?
- 2. minimize 的 BFGS 与 Nelder-Mead 各适合什么情况? 带约束时为何常用 SLSQP?
- 3. curve_fit 的 pcov 能给出参数标准误, 但什么条件下这种近似才成立?

动手练习

- 求 $x^3 - x - 1 = 0$ 在 $[1, 2]$ 内的根 (用 brentq 与 fsolve);
- 用 minimize 求 Rosenbrock 函数 $f(x, y) = (1 - x)^2 + 100(y - x^2)^2$ 的最小值 (初值 $(-1.2, 1)$);
- 用 linprog 解一个含 3 个变量、2 个不等式约束的小规划;
- 给一组 (x, y) 数据, 比较 leastsq 与 curve_fit 拟合一次线性函数 $y = ax + b$ 的结果。

延伸阅读

- SciPy 推荐拟合教程: [链接](#)
- minimize 各方法说明: [链接](#)
- scikit-learn / statsmodels 中的回归 (后续章节会用到): [链接](#)

03 插值工具包：一维/多维插值与样条

本节对应原版 3.3 的内容，并增补学习目标、常见误区、思考题与延伸阅读。所有代码均在 SciPy 1.15.2 / NumPy 2.1.2 环境实际运行验证。配套图：images/interp_compare.png (由 build/make_chap3_figures.py 生成)。

本节目标

- 理解插值 (interpolation) 与拟合 (fitting) 的区别；
- 会用 CubicSpline、一维 interp1d 做一维插值；
- 会用 RegularGridInterpolator 做规则网格上的多维插值；
- 会用 griddata 对散点数据做插值并可视化；
- 了解线性插值、样条插值的优劣与龙格现象。

先修

- 第 1 章 NumPy: meshgrid、flatten、reshape、随机数；
- Matplotlib 基础 (contourf/scatter 可选)。

官方文档 / 参考入口

- SciPy 插值模块总览: [链接](#)
 - CubicSpline: [链接](#)
 - RegularGridInterpolator: [链接](#)
 - griddata: [链接](#)
-

3.1 一维插值

已知 n 个点 (x_i, y_i) ，要在 x 的任意位置估计 y 。线性插值用直线连接数据点；三次样条用分段三次多项式，保证一阶/二阶导数连续，曲线更光滑。

3.1.1 使用 np.interp (线性)

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
x = np.array([0, 1, 2, 3, 4, 5])
y = np.array([0, 0.8, 0.9, 0.1, -0.8, -1])
print(np.interp([0.5, 2.5, 4.5], x, y))
```

[0.4 0.5 -0.9]

np.interp 只能用线性插值，速度最快。

3.1.2 经典的 interp1d (注意：新版本建议优先 CubicSpline)

```
from scipy.interpolate import interp1d
f_lin = interp1d(x, y, kind="linear")
f_cub = interp1d(x, y, kind="cubic")
print(np.round(f_lin([0.5, 2.5, 4.5]), 4))
print(np.round(f_cub([0.5, 2.5, 4.5]), 4))
```

```
[ 0.4  0.5 -0.9]
[ 0.4583  0.575 -1.0333]
```

interp1d 仍可用; 新代码建议直接用下文的 CubicSpline 或 RegularGridInterpolator (更明确、更高效)。

3.1.3 推荐: CubicSpline

```
from scipy.interpolate import CubicSpline
cs = CubicSpline(x, y)
print("cs(2.5) =", cs(2.5))
print(np.round(cs([0.5, 1.5, 2.5, 3.5, 4.5]), 4))

cs(2.5) = 0.575
[ 0.4583  0.9667  0.575 -0.3917 -1.0333]
```

注意 CubicSpline 需要至少 4 个点才能做三次样条; 点太少会自动降阶。

3.2 二维插值 (规则网格)

scipy.interpolate.interp2d 已在较新版本中废弃, 新代码推荐用 RegularGridInterpolator。它在规则网格 (x_i, y_j) 上定义函数值 $Z_{i,j}$ 。

```
from scipy.interpolate import RegularGridInterpolator
import numpy as np

xg = np.linspace(0, 3, 4)
yg = np.linspace(0, 3, 4)
X, Y = np.meshgrid(xg, yg, indexing="ij")
Z = X + Y # 简单平面 z = x + y

rgi = RegularGridInterpolator((xg, yg), Z, method="linear")
print(rgi([[1.5, 1.5], [2.0, 3.0]]))

[3. 5.]
```

点 (1.5, 1.5) 处 $z = 3$, (2, 3) 处 $z = 5$, 与真值一致。

3.3 散点插值 griddata

实验数据通常是不规则散点, 用 griddata(..., method="linear"/"cubic"/"nearest")。

```
from scipy.interpolate import griddata
rng = np.random.default_rng(0)
pts = rng.uniform(0, 10, size=(30, 2)) # 30 个散点 (x,y)
vals = np.sin(pts[:, 0]/2) + np.cos(pts[:, 1]/3)
print(griddata(pts, vals, (5, 5)))

0.2790441455976028
```

griddata 会自动三角剖分; method='cubic' 更光滑, 但需要点数足够且可能更慢。

3.4 插值 vs 拟合 (重点)

概念	插值	拟合
目标	曲线 经过所有 已知点	曲线 尽量接近 所有点
是否过点	是	否
适用数据	数据无噪声，需要精确通过	数据含噪声，希望反映整体趋势
典型工具	CubicSpline、griddata	curve_fit、np.polyfit
风险	高阶插值可能震荡（龙格现象）	模型设定错误时欠拟合/过拟合

案例卡 3：一维插值 vs 多项式拟合——缺失值用 CubicSpline 补全

目标

对一条光滑曲线 ($y = \sin x$) 采样 10 个点并故意挖掉 2 个，分别用三次样条插值 (CubicSpline) 和 3 次多项式拟合 (np.polyfit) 去补全缺失点，并比较整段误差：理解“插值贴点、拟合平滑”在补缺失值上的差异。

代码

```
import numpy as np
from scipy.interpolate import CubicSpline
np.set_printoptions(precision=4, suppress=True)

rng = np.random.default_rng(3)
x = np.linspace(0, 2*np.pi, 10)
y_true = np.sin(x)
y_obs = y_true + rng.normal(0, 0.05, x.size)
mask_ok = np.ones(x.size, dtype=bool)
mask_ok[[3, 6]] = False
x_ok = x[mask_ok]; y_ok = y_obs[mask_ok]

cs = CubicSpline(x_ok, y_ok)
coef = np.polyfit(x_ok, y_ok, 3)
poly = np.poly1d(coef)
x_miss = x[~mask_ok]
print(" 缺失点 x =", np.round(x_miss, 4))
print("CubicSpline 补全 =", np.round(cs(x_miss), 4))
print("poly3 拟合补全 =", np.round(poly(x_miss), 4))
print(" 真实值 =", np.round(y_true[~mask_ok], 4))
grid = np.linspace(0, 2*np.pi, 500)
rmse_s = np.sqrt(np.mean((cs(grid) - np.sin(grid))**2))
rmse_p = np.sqrt(np.mean((poly(grid) - np.sin(grid))**2))
print("RMSE(样条) =", round(float(rmse_s), 4))
print("RMSE(3 次多项式) =", round(float(rmse_p), 4))
```

运行结果（已运行核验）

缺失点 x = [2.0944 4.1888]
CubicSpline 补全 = [0.8895 -0.8448]
poly3 拟合补全 = [0.6857 -0.759]
真实值 = [0.866 -0.866]
RMSE(样条) = 0.0511
RMSE(3 次多项式) = 0.0958

讲解

一句话解释：插值像“用直尺/曲线板把已知点连起来”，缺失点用相邻点推；拟合像“用一条整体趋势线去平均所有点”，缺失点由全局趋势推。

- `y_obs = y_true + rng.normal(0, 0.05, x.size)`: 先给真值加一点噪声，让问题更真实（但仍是“光滑采样 + 小噪声”，更适合插值）。
- `mask_ok[[3, 6]] = False`: 把第 4、7 个点设为“缺失”，`x_ok/y_ok` 只保留未缺失点。
- `CubicSpline(x_ok, y_ok)`: 用未缺失点构造三次样条，它在缺失点处给出的 0.8895、-0.8448 贴近真实 0.866、-0.866。
- `np.polyfit(x_ok, y_ok, 3)`: 用 3 次多项式拟合未缺失点，再 `np.poly1d` 转成可调对象 `poly`；它在缺失点处给 0.6857、-0.759，偏差更大。
- 整段 500 个点的 RMSE: 样条 0.0511, 3 次多项式 0.0958。因为真值是光滑 `sin`，局部分段的样条比单片 3 次多项式更贴合；若噪声很大，则拟合更稳。

主要用法 / API

需求	写法	说明
一维三次样条插值	<code>CubicSpline(x, y)</code>	函数可调，返回 <code>cs(xnew)</code>
多项式拟合	<code>np.polyfit(x, y, deg)</code>	返回系数数组
多项式转函数	<code>np.poly1d(coef)</code>	返回可调对象
布尔缺失掩码	<code>mask = ~np.isnan(arr)</code>	选非缺失点
整段误差	<code>rmse = sqrt(mean((f(x)-true)**2))</code>	评价插值/拟合质量

常见错误

- 对有噪声的数据做样条插值：插值会“穿过噪声”，此时应改用 `curve_fit/polyfit`；
- 认为插值能“外推”缺失区间：`CubicSpline` 边界外可能明显失真，重点应放在区间内；
- `polyfit` 的阶数过高（如 9 次）会出现龙格现象（端点震荡）；
- 用 `np.polyfit` 时忘记 `x_ok/y_ok` 必须等长且无 NaN。

拓展 / 跟练

1. 把噪声标准差改成 0.4，看样条和多项式哪个更像“过拟合噪声”。
2. 缺失点换成 `mask_ok[[2, 7]]`，比较样条补全值变化。
3. 用 `interp1d(..., kind='linear')` 补全，和 `CubicSpline` 对比精度。
4. 把多项式次数从 3 改到 9，画出整段曲线观察端点震荡。

常见误区

1. 把 `interp1d/CubicSpline` 用在噪声数据上：插值会“穿过噪声”，应改用 `curve_fit`。
2. 以为 `interp2d` 是长期可用接口：新版本已推荐 `RegularGridInterpolator`。
3. 忘了 `RegularGridInterpolator` 要求**规则网格**（`(x_i, y_j)` 组合成矩形网格）；散点要用 `griddata`。
4. `griddata` 对网格外的点会返回 `nan`：外推并非其默认功能，需自行处理。
5. 使用高阶多项式插值（如 `kind=9`）在等距点上容易产生**龙格现象**（端点附近大幅震荡）。

思考题

1. 为什么样条插值一般比单个高次多项式更稳定？
2. 给定 50 个带噪声的点，你会选择插值还是拟合？为什么？
3. 用 `griddata` 插值后，如何判断待求点是否在“凸包”边界内？

动手练习

- 对 $y = \sin x$ 取 9 个等距点，分别用线性与三次样条插值，画出 $[0, 2\pi]$ 上的曲线；
- 构造 $z = \sin(x) \cos(y)$ 的规则网格 ($x, y \in [0, 2\pi]$)，用 `RegularGridInterpolator` 在网格间插值并画 `contourf`；
- 生成 100 个随机散点，用 `griddata` 做 `linear` 与 `cubic` 插值，比较两者差异。

延伸阅读

- SciPy 插值教程：[链接](#)
- SciPy 官方 `CubicSpline` 示例：[链接](#)
- 龙格现象（中文科普）：[链接](#)

04 假设检验工具包：正态性、t 检验、卡方与方差分析

本节对应原版 3.4 的内容，并增补学习目标、常见误区、思考题与延伸阅读。所有代码均在 SciPy 1.15.2 / NumPy 2.1.2 / statsmodels 0.14.6 环境实际运行验证。配套图：images/stats_boxplot.png（由 build/make_chap3_figures.py 生成）。

本节目标

- 会用 shapiro/anderson 做正态性检验；
- 会用 ttest_ind（独立样本）与 ttest_rel（配对样本）比较均值；
- 会用 chi2_contingency 检验分类变量独立性；
- 会用 f_oneway 做单因素方差分析，并用 statsmodels pairwise_tukeyhsd 做事后多重比较；
- 能正确解读 p 值，并区分“统计显著”与“实际显著”。

先修

- 概率统计基础：p 值、显著性水平、零假设；
- NumPy 随机数与统计基础；Pandas（可选）便于组织数据。

官方文档 / 参考入口

- SciPy 统计模块总览：[链接](#)
 - shapiro：[链接](#)
 - ttest_ind：[链接](#)
 - chi2_contingency：[链接](#)
-

4.1 正态性检验

许多检验（t 检验、ANOVA）都假设数据近似正态。scipy.stats 提供 Shapiro-Wilk 与 Anderson-Darling 检验。

4.1.1 Shapiro-Wilk 检验

适合小样本（ $n < 50$ 特别有效）。零假设 H_0 ：样本来自正态分布；p 值很小则拒绝 H_0 。

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
from scipy.stats import shapiro
```

```
rng = np.random.default_rng(1)
data = rng.normal(0, 1, size=100)
stat, p = shapiro(data)
print(f"W={stat:.4f}, p={p:.4f}")
if p < 0.05:
    print(" 拒绝 H0: 不认为来自正态分布")
else:
    print(" 不能拒绝 H0: 可用正态近似")
```

W=0.9802, p=0.1374

不能拒绝 H0: 可用正态近似

4.1.2 Anderson-Darling 检验

适合较大样本。它不直接给 p 值，而是给出统计量与不同显著性水平下的临界值；统计量大于某临界值则在该水平下拒绝 H_0 。

```
from scipy.stats import anderson
res = anderson(data, dist="norm")
print(f"stat={res.statistic:.4f}")
print("levels =", res.significance_level)
print("critical=", np.round(res.critical_values, 3))

stat=0.6713
levels = [15.  10.   5.   2.5  1. ]
critical= [0.555 0.632 0.759 0.885 1.053]
```

统计量 0.6713 大于 10% 临界值 0.632、但小于 5% 临界值 0.759，因此，在 5% 水平下**不能拒绝**正态性假设。

4.2 常见假设检验

4.2.1 卡方独立性检验 chi2_contingency

检验两个分类变量是否独立。对 2×2 列联表：

```
from scipy.stats import chi2_contingency
observed = np.array([[10, 20], [30, 40]])
chi2, p, dof, expected = chi2_contingency(observed)
print(f"chi2={chi2:.4f}, p={p:.4f}, dof={dof}")

chi2=0.4464, p=0.5040, dof=1
```

p 值 $0.504 > 0.05$ ，无充分证据说明两个分类变量不独立。

4.2.2 独立样本 t 检验 ttest_ind

比较两批不同样本（如高一与高三学生成绩）的均值是否不同。

```
from scipy.stats import ttest_ind
s1 = rng.normal(0, 1, size=100)      # 组 1
s2 = rng.normal(0.5, 1, size=100)    # 组 2, 均值略高
t_stat, p_val = ttest_ind(s1, s2)
print(f"t={t_stat:.4f}, p={p_val:.6f}")

t=-3.0457, p=0.002637
```

$p < 0.05$ ，拒绝“两样本均值相等”，认为组 2 均值显著高于组 1（ t 为负表示组 1 均值更低）。

4.2.3 配对样本 t 检验 ttest_rel

比较同一批对象在处理前后（如用药前后）的差异。

```
from scipy.stats import ttest_rel
before = rng.normal(0, 1, size=100)
after = before + rng.normal(0.3, 1, size=100)  # 同一批人, 均提升 0.3
t_stat, p_val = ttest_rel(before, after)
print(f"t={t_stat:.4f}, p={p_val:.8f}")

t=-4.9659, p=0.00000286
```

p 极小，说明“前后差异”在统计上显著。

4.2.4 单因素方差分析 f_oneway

比较两个及以上组的均值。

```
from scipy.stats import f_oneway
g1 = rng.normal(0, 1, size=100)
g2 = rng.normal(0.5, 1, size=100)
g3 = rng.normal(1, 1, size=100)
F, p = f_oneway(g1, g2, g3)
print(f"F={F:.4f}, p={p:.8f}")
```

F=16.7790, p=0.00000012

p 很小，说明至少两组均值不同；但 ANOVA 只告诉你“有差异”，不告诉你哪两组不同，需要事后多重比较。

4.2.5 事后多重比较：statsmodels Tukey HSD

```
import numpy as np
import statsmodels.api as sm
from statsmodels.stats.multicomp import pairwise_tukeyhsd

data = np.concatenate([g1, g2, g3])
groups = np.array(["A"]*100 + ["B"]*100 + ["C"]*100)
tukey = pairwise_tukeyhsd(data, groups, alpha=0.05)
print(tukey)
print("statsmodels", sm.__version__)
```

```
Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2 meandiff p-adj lower upper reject
-----
      A      B   0.4926 0.0045 0.1287 0.8566   True
      A      C   0.8935  0.0 0.5295 1.2574   True
      B      C   0.4008 0.0268 0.0369 0.7648   True
-----
statsmodels 0.14.6
```

可见三组之间两两差异都显著 (A-B p=0.0045, A-C p≈0, B-C p=0.0268)，说明组内噪声相较于组间差异较小。这比 ANOVA 的“整体显著”更细致。

常见误区

#	误区	正确做法
1	p<0.05 就说 “差异很大/很重要”	p 只说明 “在随机波动下不常见”，实际大小看效应量或置信区间
2	不做正态性检验就强行 t 检验	大样本可用中心极限定理近似；小样本先 shapiro 检验
3	把 ttest_ind 用于配对数据	同一批对象前后比较用 ttest_rel
4	ANOVA 显著后不做两两比较	用 Tukey HSD 找出具体差异组
5	把 “不能拒绝 H_0 ” 当成 “ H_0 成立”	只能说 “证据不足以拒绝”，尤其在样本量小时

#	误区	正确做法
6	忘记设定随机种子	统计模拟要可复现，用 <code>default_rng(seed)</code>

思考题

1. 为什么小样本 ($n < 30$) 做 t 检验前要检查正态性与方差齐性？
2. 独立样本 t 检验与配对 t 检验在数据结构和自由度上有何区别？
3. ANOVA 显著后，为什么不能直接用多个 t 检验两两比较？

动手练习

- 生成均匀分布样本并用 shapiro 检验，观察 p 值是否变小；
- 构造两组均差 0.5、标准差 1 的正态样本，比较 $n = 20$ 与 $n = 200$ 时的 p 值，说明样本量对显著性的影响；
- 给一个列联表做卡方检验，并解读 p 值；
- 用 `f_oneway` 比较 4 组数据，再用 `pairwise_tukeyhsd` 找出差异组。

延伸阅读

- SciPy 统计假设检验索引：[链接](#)
- statsmodels 多重比较官方文档：[链接](#)
- 《Python 数据分析》第 9 章统计 (Wes McKinney)，中文出版社版可参考。

05 傅里叶变换工具包：FFT、频谱分析与信号滤波

本节对应原版 3.5 的内容, 并增补学习目标、常见误区、思考题与延伸阅读。所有代码均在 SciPy 1.15.2 / NumPy 2.1.2 环境实际运行验证。配套图: `images/fft_spectrum.png` (由 `build/make_chap3_figures.py` 生成)。

本节目标

- 理解离散傅里叶变换 (DFT) 定义与 FFT 的 $O(N \log N)$ 加速;
- 会用 `scipy.fft.fft/rfft` 计算频谱, 用 `fftfreq/rfftfreq` 得到频率轴;
- 会解释单边频谱 (只取一半) 与 “幅值缩放” 的区别;
- 会用 `scipy.signal.butter+lfilter` 设计低通/高通/带通/带阻滤波器;
- 能把 “时域信号 → 频域峰值 → 滤波去噪” 串成一个流程。

先修

- 第 1 章 NumPy 数组运算; 基础三角函数相位/频率概念。

官方文档 / 参考入口

- SciPy FFT 模块总览: [链接](#)
- `rfft`: [链接](#)
- `scipy.signal` 总览: [链接](#)
- `butter`: [链接](#)

5.1 从 DFT 到 FFT

离散傅里叶变换 (DFT) 把长度为 N 的时域序列 $x[n]$ 变换为频域序列:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-2\pi i \frac{kn}{N}}, \quad k = 0, 1, \dots, N-1$$

直接计算复杂度 $O(N^2)$; 快速傅里叶变换 (FFT) 利用旋转因子的对称性与周期性, 把复杂度降到 $O(N \log N)$, 因此长信号也能秒级处理。

5.2 单边频谱: `fft` + `fftfreq`

对实信号, 频谱关于 $f_s/2$ 对称, 通常只取前半。

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
from scipy.fft import fft, fftfreq

fs = 1000          # 采样率 Hz
T = 1              # 时长 s
t = np.linspace(0, T, int(fs*T), endpoint=False)
sig = 0.7*np.sin(2*np.pi*50*t)  # 50 Hz 正弦
```

```

yf = fft(sig)
xf = fftfreq(len(yf), 1/fs)
N = len(yf)//2

peak_x = xf[np.argmax(np.abs(yf[:N]))]
peak_y = np.abs(yf[:N]).max()
print(f"peak freq = {peak_x:.1f} Hz, amplitude = {peak_y:.2f}")

peak_freq = 50.0 Hz, amplitude = 350.00

```

为什么幅值是 350 而不是 0.7? 因为 fft 未做归一化: 单边频谱取正值一半并乘以 $2/N$ 才是物理幅值。本例 $N = 1000$, 峰值 (双边) 约为 $0.7 \times 500 = 350$ 。

5.3 更省内存的 rfft + rfftfreq

实信号可用 rfft (只算一半复数), 更快且省内存。

```

import numpy as np
from scipy.fft import rfft, rfftfreq
Yr = rfft(sig)
freqs = rfftfreq(len(t), 1/fs)
print(f"peak freq = {freqs[np.argmax(np.abs(Yr))]:.1f} Hz")
print(f"n_rfft = {len(Yr)}, n_fft = {len(yf)}")

peak_freq = 50.0 Hz
n_rfft = 501, n_fft = 1000

rfft 输出约  $N/2 + 1$  个点, 与 rfftfreq 频率轴对齐。

```

5.4 用两个频率构造信号并做滤波

构造 $0.7 \sin(2\pi \cdot 50t) + \sin(2\pi \cdot 200t)$ 。频谱应在 50 Hz 与 200 Hz 出现峰值。

```

import numpy as np
sig2 = 0.7*np.sin(2*np.pi*50*t) + np.sin(2*np.pi*200*t)
Y2 = rfft(sig2)
f2 = rfftfreq(len(t), 1/fs)
top = np.argsort(np.abs(Y2))[-2:][::-1]
print("top freqs =", np.round(f2[top], 1), " amps =", np.round(np.abs(Y2[top]), 1))

top_freqs = [200.  50.]  amps = [500. 350.]

```

两个主频 200 Hz、50 Hz 恰好落在整数周期上, 因此没有明显泄漏 (若频率不是整数周期, 峰值两侧会出现旁瓣)。

5.4.1 低通滤波

用 Butterworth 低通, 保留 50 Hz、抑制 200 Hz。

```

from scipy.signal import butter, lfilter
nyq = 0.5 * fs
b, a = butter(3, 80/nyq, btype="low")
low_pass = lfilter(b, a, sig2)
print("lowpass last3 =", np.round(low_pass[-3:], 4))

lowpass_last3 = [-0.5617 -0.639 -0.6414]

```

此时输出应只剩下 50 Hz 分量（与纯 $0.7 \sin(2\pi \cdot 50t)$ 相近）。

5.4.2 高通 / 带通 / 带阻

```
b_hi, a_hi = butter(3, 120/nyq, btype="high")
high_pass = lfilter(b_hi, a_hi, sig2)
print("highpass last3 =", np.round(high_pass[-3:], 4))

b_bp, a_bp = butter(3, [60/nyq, 100/nyq], btype="band")
band_pass = lfilter(b_bp, a_bp, sig2)
print("bandpass last3 =", np.round(band_pass[-3:], 4))

b_bs, a_bs = butter(3, [150/nyq, 180/nyq], btype="bandstop")
band_stop = lfilter(b_bs, a_bs, sig2)
print("bandstop last3 =", np.round(band_stop[-3:], 4))

highpass last3 = [-0.4903 -0.9695 -0.1156]
bandpass last3 = [0.0658 0.0332 0.0031]
bandstop last3 = [-0.9061 -1.4789 -0.628 ]
```

带通只保留 60–100 Hz 附近（此区间几乎没有信号分量，故输出接近 0）；带阻削弱 150–180 Hz 一段（该处也无信号），所以输出仍接近原始信号。

常见误区

#	误区	正确做法
1	直接用 fft 幅值当作真实幅度	要除以 N 并（单边）乘 2 换算；或用 <code>rfft</code> 后作归一化
2	用 <code>fftfreq</code> 频率轴取整段画图	实数信号只画前半即可，避免无意义的镜像
3	把 <code>butter</code> 的 <code>Wn</code> 直接当 Hz	<code>Wn</code> 是归一化频率 = 截止频率 / ($f_s/2$)
4	用 <code>lfilter</code> 造成相位延迟	需要零相位可用 <code>filtfilt</code> (<code>scipy.signal.filtfilt</code>)
5	信号非整数周期导致“峰值多个旁瓣”	加窗（如 <code>scipy.signal.windows.hann</code> ）可减少频谱泄漏
6	采样率过低产生混叠	需满足 Nyquist: $f_s > 2f_{\max}$

思考题

1. 为什么对实信号用 `rfft` 比 `fft` 更划算？
2. 频谱泄漏是什么造成的？如何缓解？
3. `butter` 的阶数越高，滤波器频率响应越陡，但可能带来哪些副作用？

动手练习

- 生成 10 Hz + 30 Hz 的合成信号，画出时域与单边频谱；
- 用带通滤波器提取 10–20 Hz 分量，并比较滤波前后波形；

- 对一段含白噪声的信号做低通滤波，观察噪声幅度；
- 用 `scipy.signal.filtfilt` 替换 `lfilter`，比较相位延迟。

延伸阅读

- SciPy FFT 教程：[链接](#)
- SciPy signal 滤波教程：[链接](#)
- 数字信号处理中文教材（如《信号与系统》对应章节）可作理论补充。

06 综合案例：传感器信号分析（插值 + FFT + 拟合 + 检验 + 积分）

本案例把 01–05 的知识串起来，模拟一次真实的“传感器数据补全与建模”任务。所有代码在 SciPy/NumPy/statsmodels 环境实际运行；配图由 make_chap3_figures.py 生成。

案例背景

某传感器以 $f_s = 500$ Hz 连续采样 5 秒，真实信号为“线性漂移 + 5 Hz 主振荡 + 12 Hz 次振荡 + 测量噪声”，其中一段时间（0.30–0.32 s）数据丢失。需要：

1. 用插值补齐缺失段；
2. 用 FFT 找信号的主要频率；
3. 用 `curve_fit` 拟合参数化模型；
4. 用积分估计信号在 5 秒内的累积值；
5. 用 t 检验比较“前 1 s”与“后 1 s”的均值是否有显著差异。

生成数据与补齐缺失

```
import numpy as np
np.set_printoptions(precision=4, suppress=True)
from scipy.interpolate import CubicSpline

rng = np.random.default_rng(42)
fs = 500; T = 5.0; N = int(fs*T)
t = np.linspace(0, T, N, endpoint=False)

def true_signal(t):
    return 2 + 0.5*t + 1.2*np.sin(2*np.pi*5*t) + 0.3*np.sin(2*np.pi*12*t)

y_true = true_signal(t)
y_raw = y_true + rng.normal(0, 0.2, N)  # 加噪声

# 模拟缺失段
y_obs = y_raw.copy()
y_obs[150:160] = np.nan

# 用非缺失点做三次样条插值
mask = ~np.isnan(y_obs)
cs = CubicSpline(t[mask], y_obs[mask])
y_filled = y_obs.copy()
y_filled[150:160] = cs(t[150:160])

for i in range(150, 160, 2):
    print(f"t={t[i]:.3f}  true={y_true[i]:.4f}  raw={y_raw[i]:.4f}  \n      filled={y_filled[i]:.4f}")

t=0.300  true=1.9737  raw=1.9419  filled=1.7933
t=0.304  true=1.7611  raw=1.4262  filled=1.4313
t=0.308  true=1.5727  raw=1.5619  filled=1.3248
t=0.312  true=1.4145  raw=1.4405  filled=1.3208
t=0.316  true=1.2903  raw=1.1904  filled=1.2664
```

插值补齐值保留在真实信号附近，且比原始“丢失”更平滑。




Figure 1: 案例：含缺失段的信号插值补齐

用 FFT 找主频

先做线性去趋势，消除漂移带来的低频泄漏，再取 `rfft`。

```
from scipy.fft import rfft, rfftfreq
coef = np.polyfit(t, y_filled, 1)
detrend = y_filled - np.polyval(coef, t)

Y = rfft(detrend)
freqs = rfftfreq(N, 1/fs)
amps = np.abs(Y)
order = np.argsort(amps)[::-1]
for k in order[:5]:
    print(f"f={freqs[k]:.2f} Hz  amp={amps[k]:.2f}")

f=5.00 Hz  amp=1503.72
f=12.00 Hz  amp=371.19
f=0.20 Hz  amp=34.16
f=0.40 Hz  amp=30.74
f=19.60 Hz  amp=29.16
```

主峰在 5 Hz（次峰是 12 Hz）与建模时的真实频率完全一致；低频小峰来自去趋势后的残余。

用 `curve_fit` 拟合参数模型

模型设为“常数 + 线性漂移 + 两个正弦”：

$$y(t) = c_1 + c_2 t + A_1 \sin(2\pi f_1 t + \varphi_1) + A_2 \sin(2\pi f_2 t + \varphi_2)$$

```
from scipy.optimize import curve_fit

def model(t, c1, c2, A1, f1, p1, A2, f2, p2):
```




Figure 2: 案例: 去趋势后频谱

```
return c1 + c2*t + A1*np.sin(2*np.pi*f1*t+p1) + A2*np.sin(2*np.pi*f2*t+p2)
```

```
popt, pcov = curve_fit(model, t, y_filled,
                       p0=[2, 0.5, 1.2, 5, 0, 0.3, 12, 0], maxfev=50000)
perr = np.sqrt(np.diag(pcov))
print(" 拟合参数 =", np.round(popt, 4))
print(" 参数标准误 =", np.round(perr, 4))
resid = y_filled - model(t, *popt)
print("RMSE =", round(float(np.sqrt(np.mean(resid**2))), 4))
print(f"f1 估计 = {popt[3]:.3f}    f2 估计 = {popt[6]:.3f}")

拟合参数 = [ 1.9931  0.499   1.2042  5.0003 -0.0108  0.2977 12.0033 -0.064 ]
参数标准误 = [0.008   0.0028 0.0057 0.0005 0.0094 0.0057 0.0021 0.0382]
RMSE = 0.2009
f1 估计 = 5.000   f2 估计 = 12.003
```

拟合 $f_1 \approx 5.00$ Hz、 $f_2 \approx 12.00$ Hz, $A_1 \approx 1.20$ 、 $A_2 \approx 0.30$, 与真实模型高度一致; RMSE ≈ 0.20 正是噪声标准差。

用 trapezoid 估计累积值

```
from scipy.integrate import trapezoid
area = trapezoid(y_filled, t)
print("5 秒内信号累积值 =", round(float(area), 4))
```

5 秒内信号累积值 = 16.1939

该值可理解为“总剂量/总能量”，是积分在工程中的一个典型用途。




Figure 3: 案例：拟合曲线与残差




Figure 4: 案例：两段时间均值比较

用 t 检验比较两段时间

线性漂移使后半段均值更高，用 `ttest_ind` 验证。

```
from scipy.stats import ttest_ind
g1 = y_filled[(t >= 0) & (t < 1)]
g2 = y_filled[(t >= 4) & (t < 5)]
res = ttest_ind(g1, g2)
print(f"前 1s 均值 = {g1.mean():.4f}, 后 1s 均值 = {g2.mean():.4f}")
print(f"t={res.statistic:.3f}, p={res.pvalue:.3e}")
```

前 1s 均值 = 2.2442, 后 1s 均值 = 4.2493
 $t = -35.601$, $p = 7.475e-180$

p 值极小，说明前、后两段均值差异在统计上高度显著——这正是题目设计的线性漂移所导致的。

小结

这个案例把本章五个工具包串成一条流水线：插值补齐 (03) → FFT 定频 (05) → 非线性拟合 (02) → 积分 (01) → 假设检验 (04)。

步骤	工具	产出
补齐缺失	CubicSpline	完整时间序列
频谱分析	rffft/rfftfreq	主频 5 Hz、12 Hz
参数化建模	curve_fit	$c_1, c_2, A_1, f_1, \varphi_1, A_2, f_2, \varphi_2$
累积量	trapezoid	16.1939
均值比较	ttest_ind	$t=-35.60, p\approx 7.5e-180$

拓展任务

- 1. 把缺失段加宽（如 0.30–0.50 s），观察插值误差如何变化；
- 2. 用 `scipy.signal.butter` 低通（截止 10 Hz）滤除 12 Hz 分量后重新拟合，比较残差；
- 3. 把 “前 1 s vs 后 1 s” 换成 “前 2.5 s vs 后 2.5 s”，看 p 值变化并解释；
- 4. 用 `statsmodels` 对三段时间做单因素 ANOVA + Tukey 事后比较。

关键设计（增强）

本案例特意做了三处 “可复现工程化” 处理，适合作为课堂讲评点：

- **固定输出格式**：第 1 个代码块开头用 `np.set_printoptions(precision=4, suppress=True)`，让后面所有 NumPy 数组打印统一到 4 位有效数字，跨机器/版本更稳；
- **统一浮点格式**：每个数值都用 `round(...,4)` 或 `:.4f/:.3f` 输出，避免直接打印完整浮点（如 `0.200908...`）造成对比困难；
- **容错初值与迭代上限**：`curve_fit` 用接近真值的 `p0`，并设 `maxfev=50000`，防止复杂模型 “达到最大调用次数” 而失败；
- **先补缺失再分析**：先用 `CubicSpline` 把 NaN 段补成连续曲线，再进行 FFT / 拟合 / 积分 / 检验，保证整条流水线输入一致。

延伸阅读

- SciPy 插值 / FFT / 优化官方文档见各节 “官方文档/参考入口”。
- 信号处理完整示例：[链接](#)
- statsmodels 多重比较：[链接](#)

07 常见误区与技巧

本章为新增“查漏补缺”页：把学生在 SciPy 上最容易踩的坑集中列出，并给出正确写法、性能与调试建议。

1. 高频误区速查表

#	误区 / 错误写法	正确做法	原因
1	<code>from scipy.integrate import trapz</code>	用 <code>trapezoid</code>	SciPy 1.15 已移除 <code>trapz</code>
2	<code>odeint</code> 写 <code>func(t, y)</code>	写成 <code>func(y, t)</code>	<code>odeint</code> 的签名是 <code>(y, t)</code> , <code>solve_ivp</code> 才是 <code>(t, y)</code>
3	<code>solve_ivp(f, 0, 5, y0)</code>	<code>solve_ivp(f, (0,5), y0)</code>	<code>t_span</code> 是二元组
4	<code>quad(f,0,1)</code> 然后当数组用	<code>value, err = quad(...)</code>	<code>quad</code> 返回 <code>(value, error)</code> 元组
5	用 <code>brent</code> 求根	求根用 <code>brentq/fsolve/root</code>	<code>brent</code> 求极小值, <code>brentq</code> 求根
6	<code>linprog(c)</code> 直接当最大化用	最大化时 <code>c</code> 取负	<code>linprog</code> 默认最小化
7	<code>linear_sum_assignment</code> 后直接 <code>cost.sum()</code>	<code>cost[row_ind, col_ind].sum()</code>	返回索引配对, 需用索引取成本
8	<code>minimize</code> 约束写成 <code>fun(x) <= 0</code>	<code>ineq</code> 表示 <code>fun(x) >= 0</code>	约束符号方向易反
9	不给 <code>p0</code> 就 <code>curve_fit</code>	给接近真实值的初值	非线性最小二乘对初值敏感
10	用 <code>interp2d</code> 做新代码	用 <code>RegularGridInterpolator/griddata</code>	<code>interp2d</code> 已废弃
11	对噪声数据做样条插值	改为 <code>curve_fit/np.polyfit</code>	插值会“穿过噪声”
12	<code>griddata</code> 在凸包外直接外推	自行判断并处理 <code>nan</code>	<code>griddata</code> 不默认外推
13	<code>butter(Wn=cutoff)</code>	<code>Wn = cutoff / (fs/2)</code>	<code>Wn</code> 是归一化频率
14	把 <code>fft</code> 幅值当真实幅度	单边需乘 $2/N$; 或用 <code>rfft</code> 后归一化	<code>fft</code> 未除以 N
15	统计 $p<0.05$ 就说“差异很大”	同时看效应量/置信区间	p 值不度量重要性
16	不做正态性检验就小样本 <code>t</code> 检验	小样本先 <code>shapiro</code>	<code>t</code> 检验假设近似正态
17	ANOVA 显著后不做事后比较	用 <code>pairwise_tukeyhsd</code>	需找具体差异组
18	随机模拟不设种子	<code>default_rng(seed)</code>	便于复现与讨论

2. 原理级难点：版本迁移与新接口

SciPy 迭代较快，老教材中的某些函数已改名或废弃。写新代码时以官方最新文档为准。

老写法	新写法	说明
scipy.integrate.trapz	scipy.integrate.trapezoid	同名函数改名
scipy.integrate.odeint (仍可用)	推荐 solve_ivp	新接口更灵活，支持事件/设置
scipy.optimize.leastsq (仍可用)	推荐 curve_fit	接口更友好，返回协方差
scipy.optimize.fmin (仍可用)	minimize(method='Nelder-Mead')	统一入口
scipy.interpolate.interp2d	RegularGridInterpolator	interp2d 已废弃
scipy.fftpack	scipy.fft	新模块，接口更好

3. 性能技巧

- **向量化优先**: 能用 NumPy 数组一次算完就不要 Python 循环;
- **FFT 用 rfft**: 实数信号只用一半复数，速度与内存都省一半;
- **插值选方法**: 线性插值最快，三次样条更光滑但更慢; 大数据散点可先 cKDTree 再 griddata;
- **curve_fit 给 maxfev**: 复杂模型设 maxfev=50000 避免“达到最大调用次数”而失败;
- **积分用 quad 而非固定步长**: 自适应能在光滑区间少算、在陡峭区间加密;
- **优化设 bounds/constraints**: 有约束问题别用无约束方法，容易跑出物理合理区间;
- **多进程并行**: scipy.optimize.differential_evolution 等全局方法天然可并行，用 workers 参数。

4. 调试建议

1. **打印形状/版本**: print(x.shape, scipy.__version__), 先确认输入维度正确;
2. **检查收敛标志**: root、minimize、curve_fit 都看 success/message，别只看结果;
3. **给初值/区间**: curve_fit 用 p0; brentq 用 brack; minimize 用多组初值;
4. **固定随机种子**: default_rng(seed)，保证课堂演示与作业可复现;
5. **异常值/NaN**: 先用 np.isnan/np.isinf 检查数据，再做插值/拟合;
6. **用图直观检查**: 把数据、插值曲线、拟合曲线、频谱画出来，问题一眼可见;
7. **测试小数据**: 先用 5 个点验证函数是否返回合理，再放大到真实数据。

5. 自测清单

- ☐ 能用 quad/dblquad/trapezoid 求定积分;
- ☐ 能把二阶 ODE 化成一阶方程组并用 odeint/solve_ivp 求解;
- ☐ 能用 brentq 求根、brent 求极小值，并说清区别;
- ☐ 能用 minimize/linprog/linear_sum_assignment 解决无约束/线性规划/指派问题;
- ☐ 能用 curve_fit 拟合参数并读取 pcov;
- ☐ 能用 CubicSpline/RegularGridInterpolator/griddata 完成一维/二维/散点插值;
- ☐ 能说出插值 vs 拟合的区别;
- ☐ 能用 shapiro/ttest_ind/ttest_rel/chi2_contingency/f_oneway 完成检验并解读 p 值;
- ☐ 能用 rfft/rfftfreq 找主频，用 butter+lfilter 做滤波;
- ☐ 能独立完成 06 综合案例并解释每一步。

延伸阅读

- SciPy 官方 “Release notes” 查看版本变更: [链接](#)
- SciPy 性能 / 高阶技巧: [链接](#)

- SciPy Cookbook（老但仍有参考价值）：[链接](#)